跨细胞类型的药物响应预测及其误差来源

统计学习大作业开题报告

盛其然　洪华言　应硕丞　樊宇轩

2026 年 10 月

1　问题背景

如果对每一种 “药物 × 细胞类型” 组合都做单细胞实验，成本很高。NeurIPS 2023 单细胞扰动竞赛因此提出：**能否用某些细胞类型里测到的药物响应，预测同一药物在另一种细胞类型里的响应？**实验用人外周血单个核细胞（PBMC）加入 144 种小分子药物，24 小时后测单细胞基因表达。NK 和三类 T 细胞几乎测了所有药物，B 细胞和髓系细胞（Myeloid）只公开了 15 种药物，需要预测它们其余 255 个组合的响应。

竞赛前排方案大多已开源，主流做法是把 “药物” 和 “细胞类型” 编码为特征（如目标均值编码），在降维后的输出空间上训练神经网络或梯度提升等多输出模型，部分方案还引入了药物化学结构等外部信息。这些方案的模型框架大同小异，但较少分析**模型为什么有效、误差从何而来**，这正是本项目希望补充的部分。

2　具体研究问题

核心是**如何更准确地预测**（问题一）。问题二至四是围绕数据本身的若干小实验，从标签、噪声、生物学机制三个角度寻找影响预测的因素：一方面为改进模型提供方向，另一方面帮助解释模型为什么有效或失效。

问题一（核心）：如何用其他细胞类型的响应，更准确地预测目标细胞类型？

具体包括四个方面。

- **响应的结构**：药物响应在细胞类型之间有多少共性？18,211 维的响应中，大多数基因对大多数药物几乎没有显著变化，真正承载信号的可能只是少数基因。因此除了 “低维” 结构，我们更关心响应是否**稀疏**，以及能否先筛出有响应的基因再建模。预实验显示响应**极度重尾**：平方和最大的 5% 的行占全部平方和的 81%。
- **简单模型与复杂模型**：线性模型、核方法与神经网络差多少，复杂模型的增益来自哪里。
- **模型的可解释性**：神经网络本身难以解释，但我们可以在其基础上加入有明确含义的改进模块，再通过消融与敏感性分析说明每个模块为什么带来提升。
- **跨细胞类型的泛化**：模型在不同目标细胞类型上的表现是否一致，表现差的细胞类型和药物有什么共同特点。

问题二：标签是怎样生成的？这对预测意味着什么？

标签衡量的是**显著性**而非变化幅度：同样的药效，参与拟合的样本越多，显著性越大。主办方计算 B/Myeloid 训练标签时，可能只用了 17 种训练药物的孔（“小模型”），也可能连测试药物的孔一起用（“大模型”）。二者可用训练孔中读数全为 0 的基因区分：小模型下这类基因的 17 行标签必然完全相同；大模型下（在 T/NK 上检验）只有 35%–51% 相同。实际 B/Myeloid 标签中这类基因**全部**相同（B 139/139，Myeloid 30/30），说明**训练标签来自小模型**（自由度约 130，大模型约 380），而测试标签很可能来自大模型。因此训练标签的数值系统性偏小，模型学到的幅度也会偏小。我们将量化这一差异，并研究如何在训练和验证中加以考虑。

问题三：实验噪声给预测设了多高的上限？

标签含有任何模型都预测不出的随机噪声，因此预测误差存在下限。官方测试标签不公开，我们无法直接得知模型在测试集上“最好能做到多好”，但可以借助原始单细胞数据估计噪声的大小。预实验中，我们分别算出 3 位供体各自的表达变化：NK 和 $CD4^+$ 中供体间相关系数的中位数只有 0.04 和 0.12，最强的 10% 的药物也仅 0.26 和 0.37，即**大多数药物的响应在供体之间几乎重复不出来**。我们要估计误差下限，回答现有模型离它多远、剩余误差来自方向、幅度还是噪声，从而判断改进的方向。

问题四：细胞类型特异性响应能否由药物靶点的表达解释？

预测依赖借用其他细胞类型中同一药物的响应；若药物只在某一种细胞类型中起强作用，所有模型都会失效。一个可能的解释是：药物通过结合靶点或受体蛋白起作用，只有表达该靶点的细胞才会响应。我们打算从公开数据库整理药物靶点，用对照样本算出靶点在各细胞类型中的表达，检验这一解释是否普遍成立，再把“靶点在目标细胞中是否表达”作为新特征加入模型。这既回答了“药物本身的信息能否帮助预测”，也为模型提供生物学上的解释。

3 数据来源

数据来自 Kaggle 竞赛页面。

- **主数据** `de_train.parquet`：614 行“细胞类型 × 药物”组合，每行是 18,211 个基因的 $\mathrm{sign}(\log \mathrm{FC}) \times (-\log_{10} p)$。B 和 Myeloid 只有 15 种药物（下称**锚点药物**）及 2 种对照。
- **辅助数据**：官方公开的训练部分原始单细胞计数 `adata_train.parquet` 及样本信息（3 位供体），用于问题二至四。
- **外部数据**：药物靶点从 LINCS、ChEMBL 等公开数据库整理；竞赛前排的开源方案作为参考。

不使用任何测试集标签或测试集原始数据。

4 初步建模思路

以下为初步设想，具体方法将根据实验结果调整。

问题一：预测模型。

- **基线与线性模型**：全零预测、已知药物均值等朴素基线，以及岭回归、核岭回归等线性或核方法，作为比较的基准。
- **输出降维与稀疏化**：输出维度（18,211）远大于样本量（614），需要先压缩输出。我们将比较两种思路：用截断 SVD 等方法得到低维表示，或先筛出在多数药物上有显著响应的少数基因，只对这些基因建模。
- **多任务学习**：把每个已知细胞类型的预测看作一个任务，各任务共享药物层面的特征，再把学到的共享结构迁移到 B/Myeloid。
- **神经网络**：在已有的神经网络模型（参考开源的前排方案）基础上，加入有明确含义的改进模块，如针对重尾的幅度模块、问题二的标签尺度校准、问题四的靶点特征，以及基因本身的信息（如基因在各细胞类型中的基础表达）。
- **消融与敏感性分析**：逐个去掉模块或遮盖部分输入，观察误差变化，判断各部分的重要性；对输入施加小幅扰动（如 5%–10%），检验预测是否稳定。

问题二至四：数据分析。

- **问题二**：用原始计数复现 Limma 流程，模拟小模型与大模型，量化两者的差异，并检验据此校准预测幅度能否改进预测。
- **问题三**：按供体拆分原始数据，估计标签噪声，得到误差下限；把各模型误差拆成方向、幅度、噪声三部分。
- **问题四**：整理靶点注释并计算靶点在各细胞类型中的表达，检验其与响应特异性的关系，再作为特征加入模型。

5 评价方案

评价遵循两条原则：一是验证集要**模拟真实任务**，即目标细胞类型只知道少数锚点药物，因此不用随机划分；二是**测试数据不参与训练和调参**。初步设想两种方案：**方案 A** 轮流把一个数据完整的 T/NK 细胞类型当作 “新细胞类型”，只保留其锚点药物，其余药物作为测试，超参数在其余细胞类型上用同样方式选取；**方案 B** 在 B/Myeloid 的锚点药物上做留一验证，直接针对目标细胞类型，但样本较少，作为补充。评价指标以竞赛指标 MRRMSE 为主，并辅以置信区间等不确定性度量；方案 A 还可以分别报告各目标细胞类型上的表现，用于回答问题一中的泛化问题。具体方案将随研究进展调整，例如问题二若证实训练与测试标签的生成方式不同，验证集也需相应修正。

6 可能困难

1. **输出维度远大于样本量**，且大部分基因接近噪声：通过降维或基因筛选压缩输出，并比较不同压缩方式的影响。
2. **神经网络可解释性差**：不直接解释网络本身，而是通过消融与敏感性分析解释各改进模块的作用。
3. **供体只有 3 位**，噪声估计不稳定：尝试多种拆分方式并报告敏感性。
4. **锚点药物只有 15 种**，B/Myeloid 上样本少：主要在 T/NK 上检验，再到 B/Myeloid 上验证。
5. **原始单细胞数据量大**，读取和处理较慢：先汇总为伪 bulk 数据，并利用课题组的 GPU 服务器计算。

7 初步分工与进度

初步分工如下，后续可根据进展和个人兴趣灵活调整：应硕丞负责问题一（预测模型、消融与敏感性分析）；盛其然负责统筹与问题二；洪华言负责问题三；樊宇轩负责问题四。重要结果由不同成员独立复核（交叉验证），代码统一整理在 GitHub 仓库中，保证可复现。

进度安排：

- **10 月**：整理并共享已有模型和代码，统一训练与验证流程；开始问题二至四的数据分析。
- **11 月上旬**（期中考试期间）：以数据分析为主，完成中期汇报。
- **11 月中旬起**：在已有模型上进行改进、消融与敏感性实验，把问题二至四的结论接入模型。
- **12 月**：统一评估，整理代码，撰写最终报告。